



## گزارش پروژه پایانی

مریم سادات هاشمی  
دانشکده مهندسی کامپیوتر  
دانشگاه علم و صنعت ایران  
m\_hashemi94@comp.iust.ac.ir

### چکیده

تهیه داده‌های دارای برچسب برای آموزش الگوریتم‌های یادگیری ماشین بسیار مهم است. با این حال، بدست آوردن تعداد کافی از داده‌های برچسب‌دار در کاربردهای واقعی اغلب گران و زمانبر است. بنابراین روش‌هایی که دانش موجود در یک دامنه با برچسب‌گذاری مناسب (دامنه مبدا) را به یک دامنه با برچسب‌های معدود یا بدون برچسب (دامنه هدف) منتقل می‌کنند، موثر هستند. به این روش‌ها انتقال یادگیری، تطبیق دامنه و یا تطبیق توزیع می‌گویند. از آنجا که دامنه‌های مبدا و هدف دارای توزیع‌های مختلف هستند، روش‌های بیشمار برای کاهش واگرایی توزیع‌ها پیشنهاد شده است. در این پروژه به بررسی یک روش پارامتری به نام BDA و یک روش غیر پارامتری EasyTL برای انجام تطبیق دامنه می‌پردازیم.

### ۱ مقدمه

لورم ایپسوم متن ساختگی با تولید سادگی نامفهوم از صنعت چاپ و با استفاده از طراحان گرافیک است. چاپگرها و متون بلکه روزنامه و مجله در ستون و سطرآنچنان که لازم است و برای شرایط فعلی تکنولوژی مورد نیاز و کاربردهای متنوع با هدف بهبود ابزارهای کاربردی می‌باشد. [۱]

### ۲ ادبیات موضوع

لورم ایپسوم متن ساختگی با تولید سادگی نامفهوم از صنعت چاپ و با استفاده از طراحان گرافیک است. چاپگرها و متون بلکه روزنامه و مجله در ستون و سطرآنچنان که لازم است و برای شرایط فعلی تکنولوژی مورد نیاز و کاربردهای متنوع با هدف بهبود ابزارهای کاربردی می‌باشد. [۲]

### ۳ شرح روش پیشنهادی مقالات

در این بخش ابتدا مسئله تطبیق دامنه را به صورت ریاضی بیان می‌کنیم. سپس مشکلات و چالش‌هایی که در حل این مسئله وجود دارد را بیان خواهیم کرد. در ادامه نیز توضیح خواهیم داد که هر کدام از مقاله‌ها چه روشی را برای حل این مشکلات و چالش‌ها ارائه داده‌اند.

#### ۱.۳ تعریف ریاضی مسئله تطبیق دامنه

ما یک دامنه‌ی برچسب خورده به نام دامنه مبدا و یک دامنه برچسب نخورده به نام دامنه هدف داریم که به ترتیب به صورت  $\{x_{t_j}\}_{j=1}^m$  و  $\{x_{s_i}, y_{s_i}\}_{i=1}^n$  تعریف می‌شود. همچنین فرضیاتی را در مورد فضای ویژگی‌ها  $X_s = X_t$  و فضای برچسب‌ها

$Y_s = Y_t$  و احتمال حاشیه‌ای  $P_s(x_s) \neq P_t(x_t)$  و احتمال شرطی  $P_s(y_s|x_s) \neq P_t(y_t|x_t)$  در نظر می‌گیریم. بنابراین هدف انتقال یادگیری این است که فضای پرچسب‌های دامنه هدف  $Y_t$  را به کمک دامنه مبدا  $D_s$  یاد بگیرد. تطبیق دامنه تلاش می‌کند که با کاهش واگرایی احتمال‌های حاشیه‌ای و احتمال‌های شرطی بین دامنه‌ی مبدا و هدف، مسئله انتقال یادگیری را حل کند به عبارت دیگر واگرایی بین (۱)  $P_s(x_s)$  و  $P_t(x_t)$ ، (۲)  $P_s(y_s|x_s)$  و  $P_t(y_t|x_t)$  را به حداقل می‌رساند.

### ۲.۳ تطبیق متوازن دامنه در یادگیری انتقال<sup>۱</sup>

بسیاری از روش‌های تطبیق توزیع موجود، یکی از توزیع‌های حاشیه‌ای یا شرطی و یا هر دو را تطبیق می‌دهند. در مقاله‌های اخیر ثابت شده است که استفاده از هر دو توزیع عملکرد بهتری را نتیجه می‌دهد. اما روش‌های کنونی تاثیر هر دو توزیع را یکسان در نظر می‌گیرند در حالی که وقتی مجموعه داده‌ها بسیار متفاوت باشند، به این معنی است که توزیع حاشیه‌ای اهمیت بیشتری دارد و وقتی مجموعه داده‌ها مشابه هستند، به این معنی است که توزیع شرطی به توجه بیشتری نیاز دارد. از این رو، لازم است از هر دو توزیع با وزنی مناسب با اهمیت آن‌ها برای تطبیق استفاده نمود. علاوه بر این، نامتوازن بودن مجموعه داده بر روی تطبیق دامنه تاثیرگذار است که در روش‌های موجود این موضوع در نظر گرفته نمی‌شود. برای حل این دو مشکل، در [۱] دو روش پیشنهاد شده است. روش اول BDA است که نه تنها می‌تواند توزیع‌های حاشیه‌ای و شرطی بین حوزه‌ها را تطبیق دهد، بلکه اهمیت این دو توزیع را به صورت متوازن تنظیم می‌کند. روش دوم W-BDA است که مشکل نامتوازن بودن مجموعه داده را حل می‌کند. W-BDA می‌تواند هنگام انجام تطبیق توزیع، وزن هر کلاس را به طور انطباقی تغییر دهد.

#### BDA ۱.۲.۳

همانطور که توضیح دادیم در تطبیق دامنه، با کاهش واگرایی یا فاصله‌ی بین احتمال‌های حاشیه‌ای و شرطی می‌توانیم دامنه‌های مبدا و هدف را تطبیق دهیم. این موضوع را می‌توانیم به صورت عبارت زیر بیان کنیم:

$$Dist(D_s, D_t) \approx Dist(P(x_s), P(x_t)) + Dist(P(y_s|x_s), P(y_t|x_t)) \quad (۱)$$

روش BDA به عبارت ۱ یک ضریب توازن به نام  $\mu$  اضافه می‌کند که میزان اهمیت توزیع حاشیه‌ای و شرطی را در مسائل مختلف تنظیم و کنترل می‌کند. پس عبارت ۱ تبدیل می‌شود به:

$$Dist(D_s, D_t) \approx (1 - \mu)Dist(P(x_s), P(x_t)) + \mu Dist(P(y_s|x_s), P(y_t|x_t)) \quad (۲)$$

برای حل عبارت ۲ از روش MMD برای تخمین توزیع‌های حاشیه‌ای و توزیع‌های شرطی استفاده می‌کنیم. بنابراین خواهیم داشت:

$$D(D_s, D_t) \approx (1 - \mu) \left\| \frac{1}{n} \sum_{i=1}^n x_{s_i} - \frac{1}{m} \sum_{j=1}^m x_{t_j} \right\|_H^2 + \mu \sum_{c=1}^C \left\| \frac{1}{n_c} \sum_{x_{s_i} \in D_s^{(c)}} x_{s_i} - \frac{1}{m_c} \sum_{x_{t_j} \in D_t^{(c)}} x_{t_j} \right\|_H^2 \quad (۳)$$

در عبارت ۳ ترم اول فاصله‌ی توزیع‌های حاشیه‌ای بین دامنه‌ها را نشان می‌دهد و ترم دوم هم فاصله‌ی توزیع‌های شرطی بین دامنه‌ها را نمایش می‌دهد. با بهره‌گیری از تکنیک‌های ماتریس و جبر خطی عبارت ۳ را می‌توان به صورت زیر نوشت:

$$\min_{s.t.} \quad tr \left( A^T X \left( (1 - \mu) M_0 + \mu \sum_{c=1}^C M_c \right) X^T A \right) + \lambda \|A\|_F^2 \quad (۴)$$

$$A^T X H X^T A = I, \quad 0 \leq \mu \leq 1$$

در عبارت ۴ دو ترم وجود دارد: (۱) تطبیق توزیع‌های حاشیه‌ای و شرطی به همراه ضریب توازن  $\mu$  (۲) ترم مربوط به رگلاریسیون با ضریب رگلاریسیون  $\lambda$ . در این عبارت ۲ قید هم داریم. قید اول بیان می‌کند که داده‌ی تغییر یافته ویژگی‌های داخلی اصل داده را حفظ می‌کند. قید دوم نیز بازه‌ی ضریب توازن را بیان می‌کند.

برای حل عبارت ۴ از ضرائب لاگرانژ استفاده می‌کنیم. بنابراین اگر ضرائب لاگرانژ  $\phi = \{\phi_1, \phi_2, \dots, \phi_d\}$  باشد، خواهیم داشت:

$$L = tr \left( A^T X \left( (1 - \mu) M_0 + \mu \sum_{c=1}^C M_c \right) X^T A \right) + \lambda \|A\|_F^2 + tr((I - A^T X H X^T A) \phi) \quad (۵)$$

## الگوریتم BDA

ورودی: ماتریس ویژگی  $X_s$  و  $X_t$ ، بردار برچسب مبدا  $y_s$ ، تعداد بعد  $d$ ، ضریب توازن  $\mu$ ، پارمتر رگلاریسین  $\lambda$ .

خروجی: ماتریس تبدیل  $A$  و طبقه‌بند  $f$ .

- ۱: یک طبقه‌بند پایه را روی  $X_s$  آموزش دهید و پیش‌بینی را روی اعمال کنید تا برچسب‌های آن را بدست آورید. ماتریس  $X = [X_s, X_t]$  را بسازید. ماتریس‌های  $M_0$  و  $M_c$  را مقداردهی اولیه کنید. (یا  $W_c$  برای  $W$ -BDA)
- ۲: مراحل زیر را تا وقتی که همگرایی رخ دهد ادامه دهید.
- ۳: معادله (۵) را حل کنید. (یا معادله (۸) برای  $W$ -BDA) و از  $d$  کوچکترین بردار برای ساخت  $A$  استفاده کنید.
- ۴: طبقه‌بند  $f$  را بر روی  $\{A^T X_s, y_s\}$  آموزش دهید.
- ۵: برچسب‌های  $A^T X_t = f(A^T X_t)$  را به‌روز کنید.
- ۶: ماتریس  $M_c$  را به‌روز کنید. (یا  $W_c$  برای  $W$ -BDA)
- ۷: طبقه‌بند  $f$  را برگردانید.

## شکل ۱

برای بدست آوردن ماتریس تبدیل  $A$  کافی است از عبارت ۵ نسبت به  $A$  مشتق بگیریم و برابر صفر بگذاریم. در این صورت به عبارت زیر دست می‌یابیم:

$$\left( X \left( (1 - \mu) M_0 + \mu \sum_{c=1}^C M_c \right) X^T + \lambda I \right) A = X H X^T A \phi \quad (6)$$

عبارت ۶ همان معادله‌ی معروف بردار و مقدار ویژه است. پس با پیدا کردن  $d$  بردار ویژه با کمترین مقدار ویژه خواهیم توانست ماتریس تبدیل  $A$  را بدست آوریم. در اینجا سوالی پیش می‌آید که چرا مقدار بهینه  $\mu$  را بدست نیاوردیم. نکته‌ی حائز اهمیت در اینجا این است که پارمتر  $\mu$  یک پارامتر آزاد نیست که بتوانیم آن را تخمین بزنیم بلکه  $\mu$  با توجه به توزیع داده‌ها تخمین زده می‌شود. بنابراین در واقعیت باید با توجه به کاربرد و با استفاده از روش ارزیابی متقابل مقدار بهینه  $\mu$  را بدست آوریم.

## ۲.۲.۳ W-BDA


روش W-BDA همانند روش WBDA است با این تفاوت که با در نظر گرفتن نامتوازن بودن کلاس‌ها در داده‌ها تخمین دقیق‌تری را برای احتمال شرطی تعریف می‌کند. همانطور که می‌دانیم در واقعیت ما نمیتوانیم احتمال  $P(y|x)$  را به صورت مستقیم تخمین بزنیم به همین دلیل با استفاده از قانون بیز به جای آن احتمال  $P(x|y)$  را تخمین می‌زنیم. روش W-BDA برای تخمین احتمال پیشین داده‌های موجود در دامنه مبدا و هدف به ترتیب از دو ضریب  $\alpha_s$  و  $\alpha_t$  استفاده می‌کند که با استفاده از آن‌ها تناسب کلاس‌های هر دامنه را متوازن می‌کند. اگر بخواهیم این مسئله را به صورت ریاضی بیان کنیم خواهیم داشت:

$$\begin{aligned} Dist(P(y_s|x_s), P(y_t|x_t)) &= \|P(y_s|x_s) - P(y_t|x_t)\|_H^2 \\ &= \left\| \frac{P(y_s)}{P(x_s)} P(y_s|x_s) - \frac{P(y_t)}{P(x_t)} P(y_t|x_t) \right\|_H^2 \\ &= \|\alpha_s P(y_s|x_s) - \alpha_t P(y_t|x_t)\|_H^2 \end{aligned} \quad (7)$$

بنابراین با توجه به توضیحات بالا در روش W-BDA کافی است معادله‌ی ۴ را به معادله‌ی زیر تغییر دهیم:

$$\begin{aligned} \min \quad & tr \left( A^T X \left( (1 - \mu) M_0 + \mu \sum_{c=1}^C W_c \right) X^T A \right) + \lambda \|A\|_F^2 \\ \text{s.t.} \quad & A^T X H X^T A = I, \quad 0 \leq \mu \leq 1 \end{aligned} \quad (8)$$

به طور خلاصه الگوریتم دو روش BDA و W-BDA را می‌توانید در شکل ۱ مشاهده کنید.



شکل ۲: فرآیند روش EasyTL

### ۳.۳ انتقال یادگیری آسان با استفاده از ساختارهای درون دامنه<sup>۲</sup>

بیشتر روش‌های سنتی و عمیق در انتقال یادگیری، روش‌های پارامتری است که باید طی فرآیندی بسیار گران قیمت و وقت گیر پارامترهای آن را تنظیم کند. ارزیابی متقابل، که متداول‌ترین استراتژی برای انتخاب مدل‌ها و تنظیم پارامترها است، در انتقال یادگیری قابل استفاده نیست زیرا اغلب داده‌های پرچسب خورده در دامنه هدف وجود ندارد. اگرچه روش‌های اخیر AutoML می‌تواند به طور خودکار پارامترها را از طریق هرس درخت، boosting و شبکه‌های عصبی تنظیم کنند اما آن‌ها قادر به مدیریت توزیع‌های مختلف بین دامنه‌ها نیستند و به طور معمول مدت زمان زیادی برای همگرایی لازم دارند. در مقاله [۲] الگوریتمی پیشنهاد شده است که روشی ساده اما کارآمد را پیشنهاد می‌دهد که علاوه بر این که مشکلات ذکر شده را حل می‌کند، این امکان را فراهم می‌کند که بتوان الگوریتم یادگیری انتقال را بر روی دستگاه‌های کوچک که دارای منابع محاسباتی محدود هستند نیز اجرا کرد. اسم این روش را EasyTL نامیدند. EasyTL قادر است بدون نیاز به انتخاب مدل و تنظیم هاپیرپارامترها، انتقال دانش را در دامنه‌ها انجام دهد. EasyTL با بهره برداری از ساختارهای درون دامنه، هم انتقال ویژگی‌ها و هم انتقال طبقه‌بند را به صورت غیر پارامتری می‌آموزد. برای انتقال ویژگی‌ها روشی به نام *intra-domain alignment* و برای انتقال طبقه‌بند روشی به نام *intra-domain programming* را معرفی کرده است (شکل ۲). در ادامه به توضیح جزئیات هر کدام از این روش‌ها می‌پردازیم.

#### ۱.۳.۳ intra-domain programming

در این بخش می‌خواهیم بررسی کنیم که روش *intra-domain programming* چگونه می‌تواند طبقه بند دامنه مبدا را به دامنه هدف منتقل کند. قبل از اینکه به سراغ جزئیات این روش ببریم، مفهومی را به نام ماتریس احتمال M معرفی می‌کنیم. سطرهای این ماتریس تعداد کلاس‌ها و ستون‌های آن برابر با تعداد نمونه‌های موجود در مجموعه داده است. هر درایه از این ماتریس نشان می‌دهد که چقدر احتمال دارد یک نمونه متعلق به کلاس آن سطر باشد. بنابراین جمع احتمال‌های یک ستون در این ماتریس برابر یک است.

$$M = \begin{matrix} & \begin{matrix} x_1^t & x_2^t & x_3^t & \dots & x_n^t \end{matrix} \\ \begin{matrix} c_1 \\ c_2 \\ c_3 \\ c_4 \end{matrix} & \begin{bmatrix} 0.1 & 0.2 & 0.5 & \dots & \dots \\ 0.2 & 0.4 & 0.1 & \dots & \dots \\ 0.3 & 0.2 & 0.2 & \dots & \dots \\ 0.4 & 0.2 & 0.2 & \dots & \dots \end{bmatrix} \end{matrix}$$

شکل ۳: یک مثال از ماتریس احتمال M

در روش *intra-domain programming* به حای اینکه مستقیماً

را بیاموزد، تلاش می‌کند تا ماتریس احتمال M را بدست آورد. از این رو تابع هزینه به صورت زیر تعریف می‌شود:

$$J = \sum_j^{n_t} \sum_c^C D_{cj} M_{cj} \quad (9)$$

در عبارت ۹ ماتریس D ماتریس فاصله است که درایه ی  $D_{cj}$  نشان دهنده ی فاصله ی نمونه ی  $x_j^t$  تا مرکز c امین کلاس در دامنه مبدا است. اگر  $h_c$  را به عنوان مرکز c امین کلاس در دامنه مبدا در نظر بگیریم؛ در این صورت  $D_{cj}$  و  $h_c$  به ترتیب به

صورت زیر محاسبه می شود:

$$D_{cj} = \left\| x_t^j - h_c \right\| \quad (۱۰)$$

$$h_c = \frac{1}{|\Omega_s^{(c)}|} \sum_i^{n_s} x_i^s \cdot \mathbb{I}(y_i^s = c) \quad (۱۱)$$

اکنون برای آن که ماتریس احتمال  $M$  را بدست آوریم باید تابع هزینه معادله ۹ را به حداقل برسانید. بدین منظور قید هایی برای این تابع تعریف می شود. اولین قید است که جمع احتمال هر ستون از ماتریس  $M$  برابر با یک باشد. قید دومی که تعریف می شود این است که حداقل باید برای هر کلاس یک نمونه وجود داشته باشد و قید سوم هم همانطور که می دانیم مقدار هر درایه از ماتریس  $M$  باید یک عدد در بازه ی صفر تا یک باشد. بنابراین به صورت ریاضی داریم:

$$\begin{aligned} \min \quad & \mathbf{J} = \sum_j^{n_t} \sum_c^C D_{cj} M_{cj} \quad s.t \\ & 0 \leq M_{cj} \leq 1, \\ & \sum_c^C M_{cj} = 1, \quad \forall j \in 1, \dots, n_t, \\ & \sum_j^{n_t} M_{cj} \geq 1, \quad \forall c \in 1, \dots, C \end{aligned} \quad (۱۲)$$

برای حل عبارت ۱۲ از پکیج PuLP در پایتون استفاده می کنیم و در نهایت ماتریس  $M$  بدست می آید. در گام آخر برچسب نمونه  $x_j^t$  به شکل زیر محاسبه می گردد:

$$y_j^t = \underset{r}{argmax} \frac{M_{rj}}{\sum_c^C M_{cj}} \quad for \quad r \in \{1, \dots, C\} \quad (۱۳)$$

نکته ی قابل توجه در این روش این است که هیچ پارامتری در این روش وجود ندارد که نیاز ب تنظیم کردن داشته باشد. به همین علت است که به این روش، روش غیر پارامتری می گوئیم.

### ۲.۳.۳ intra-domain alignment

همانطور که در شکل ۲ مشخص است؛ هدف از *intra-domain alignment* تطبیق ویژگی ها بین دامنه ی مبدا و هدف است که باعث کم شدن واگرایی بین دامنه ها می شود. روش هایی زیادی برای این کار وجود دارد مانند BDA و GFK. اما در اینجا ما از روش *CORrelation ALIGNment* استفاده می کنیم که هم از لحاظ محاسباتی کارآمد است و هم یک روش غیر پارامتری است. فرمولی که این روش برای تطبیق دامنه ها معرفی می کند به صورت زیر است:

$$z^r = \begin{cases} x^r \cdot (cov(x^s) + E_s)^{-\frac{1}{2}} \cdot (cov(x^t) + E_t)^{\frac{1}{2}} & if \quad r = s \\ x^r & if \quad r = t \end{cases} \quad (۱۴)$$

الگوریتم روش *EasyTl* را به طور خلاصه می توانید در شکل ۴ مشاهده کنید.

## ۴ پیاده سازی و نتایج

همان طور که در [۲] بیان شده است در روش *EasyTL* باید دو قسمت زیر را پیاده سازی کنیم:

۱. *Intra-domain programming*

۲. *Intra-domain alignment*

بخش *Intra-domain programming* شامل ۳ مرحله نیز می باشد:

ورودی: ماتریس ویژگی  $x_s$  و  $x_e$  برای  $\Omega_s$  و  $\Omega_e$  و بردار برجسب  $y_s$  برای  $\Omega_s$ .


خروجی: بردار برجسب پیش بینی شده  $y_e$  برای دامنه هدف.

۱: (اختیاری) انجام intra-domain alignment.

۲: بدست آوردن ماتریس احتمال  $M$  و محاسبه  $y_e$  با حل معادله (۱۲).

۳: بردار برجسب  $y_e$  برای  $\Omega_e$ .

شکل ۴



شکل ۵: نتایج روش EasyTL بر روی مجموعه داده Amazon Review

۱. محاسبه بردار مراکز کلاس‌های دامنه‌ی مبدا  $h_c$ : این قسمت در تابع  $get\_class\_center(X_s, Y_s)$  پیاده‌سازی شده است.

۲. محاسبه ماتریس فاصله  $D$ : این قسمت در تابع  $get\_distance\_matrix(X_t, class\_center)$  پیاده‌سازی شده است.

۳. بدست آوردن ماتریس احتمال  $M$  با استفاده از معادله‌ی فلان و بدست آوردن برجسب دامنه هدف: این قسمت در تابع  $solve\_LP(C, nt, Decj)$  پیاده‌سازی شده است.

سپس از نتایج این سه تابع استفاده می‌کنیم و آن‌ها را در تابع  $intra\_domain\_programming(X_s, Y_s, X_t, Y_t)$  با هم ترکیب می‌کنیم. در بخش  $Intra\_domain\_alignment$  کافی است تنها معادله‌ی فلان را پیاده‌سازی کنیم. بدین منظور از تابع  $intra\_domain\_alignment(X_s, X_t)$  استفاده می‌کنیم.

روش EasyTL را می‌توانیم به دو صورت اجرا کنیم. در یک حالت فضای دامنه‌ها را بایکدیگر تراز نمی‌کنیم و فقط بخش  $Intra\_domain\_programming$  را اجرا می‌کنیم و در حالت دیگر ابتدا فضای دامنه‌ها را به یکدیگر تراز می‌کنیم و سپس طبقه‌بند موجود در دامنه مبدا را به دامنه هدف منتقل می‌کنیم. این روش را بر روی ۴ مجموعه داده آزمایش می‌کنیم و نتایج را مقایسه می‌کنیم. این ۴ مجموعه داده به شرح زیر هستند:


۱. *Amazon Review* یک مجموعه داده تجزیه و تحلیل احساسات است که شامل بررسی‌های مثبت و منفی چهار نوع محصول است: لوازم آشپزخانه، دی وی دی، الکترونیک و کتاب

۲. *Office-Caltech* شامل ۱۰ کلاس از تصاویر در آمازون، DSLR، وب کم و Caltech است.


۳. *Image-CLEF DA* شامل ۱۲ دسته تصویر متعلق به ۳ حوزه است: Caltech، ImageNet و Pascal.

۴. *Office-Home* شامل ۱۵،۵۰۰ تصویر از ۶۵ دسته از ۴ حوزه، Product، Clipart Art، و دنیای واقعی است.

نتایج اجرای روش EasyTL را بر روی ۴ تا مجموعه داده ذکر شده را در شکل‌های ۵، ۶، ۷ و ۸ می‌توانید مشاهده کنید. از مقایسه‌ی شکل‌های قسمت (آ) در تمامی شکل‌های ۵، ۶، ۷ و ۸ با نتایج مقاله به این نتیجه می‌رسیم که دقت‌هایی که بدست



(ج)




(ب)

Accuracy on Image-CLEF DA dataset


Task	EasyTL	EasyTL without alignment
c - i	91.5 %	85.5 %
c - p	77.7 %	72.0 %
i - c	96.0 %	93.3 %
i - p	78.7 %	78.5 %
p - c	95.0 %	91.0 %
p - i	90.3 %	89.5 %

(آ)

شکل ۶: نتایج روش *EasyTL* بر روی مجموعه داده *Image-CLEF DA*



(ج)



(ب)

Accuracy on Office-Caltech dataset

Task	EasyTL	EasyTL without alignment
caltech10 - amazon	52.6 %	50.1 %
caltech10 - webcam	53.9 %	49.5 %
caltech10 - dsfr	51.6 %	48.4 %
amazon - caltech10	42.3 %	43.0 %
amazon - webcam	43.1 %	40.7 %
amazon - dsfr	48.4 %	38.9 %
webcam - caltech10	35.4 %	29.7 %
webcam - amazon	38.2 %	35.2 %
webcam - dsfr	79.6 %	77.1 %
dsfr - caltech10	36.1 %	31.2 %
dsfr - amazon	38.3 %	31.9 %
dsfr - webcam	86.1 %	69.5 %


(آ)

شکل ۷: نتایج روش *EasyTL* بر روی مجموعه داده *Office-Caltech*


آوردیم کاملاً مطابق با دقت‌های مقاله است. از شکل‌های قسمت (ب) و (ج) در تمامی شکل‌های ۵، ۶، ۷ و ۸ می‌توانیم به یک نتیجه‌گیری کلی برسیم و آن این است که دقت در حالتی که روش *EasyTL* را بدون تراز کردن اجرا می‌کنیم با حالتی که تراز کردن را در نظر نمی‌گیریم تفاوت چندانی ندارد اما از لحاظ زمان و سرعت روش *EasyTL* بدون تراز کردن بسیار سریعتر است و نیاز به زمان کمتری دارد. بنابراین در کاربردهایی که دقت برای ما از اهمیت بالایی برخوردار است می‌توانیم از روش *EasyTL* با تراز کردن استفاده کنیم و در کاربردهایی که سرعت برای ما مهم است روش *EasyTL* را بدون تراز کردن استفاده کنیم. به عبارت دیگر در اینجا با یک مصالحه‌ای رو به رو هستیم که با توجه به کاربرد باید تصمیم بگیریم که از کدام روش استفاده کنیم.

## مراجع

- [1] J. Wang, Y. Chen, S. Hao, W. Feng, and Z. Shen. Balanced distribution adaptation for transfer learning. In *2017 IEEE International Conference on Data Mining (ICDM)*, pages 1129–1134. IEEE, 2017.
- [2] J. Wang, Y. Chen, H. Yu, M. Huang, and Q. Yang. Easy transfer learning by exploiting intra-domain structures. In *2019 IEEE International Conference on Multimedia and*



(ج)



(ب)

Accuracy on Office-Home dataset

Task	EasyTL	EasyTL without alignment
Art - Clipart	52.8 %	51.5 %
Art - Product	72.1 %	68.1 %
Art - RealWorld	75.9 %	74.2 %
Clipart - Art	55.0 %	53.1 %
Clipart - Product	65.9 %	62.9 %
Clipart - RealWorld	67.6 %	65.3 %
Product - Art	54.4 %	52.8 %
Product - Clipart	46.9 %	45.8 %
Product - RealWorld	74.7 %	73.5 %
RealWorld - Art	63.8 %	62.2 %
RealWorld - Clipart	52.3 %	50.1 %
RealWorld - Product	77.9 %	76.0 %

(آ)

شکل ۸: نتایج روش *EasyTL* بر روی مجموعه داده *Office-Home*

*Expo (ICME)*, pages 1210–1215. IEEE, 2019.