



## گزارش پروژه پایانی

مریم سادات هاشمی  
دانشکده مهندسی کامپیوتر  
دانشگاه علم و صنعت ایران  
m\_hashemi94@comp.iust.ac.ir

### چکیده

تهیه داده‌های دارای برچسب برای آموزش الگوریتم‌های یادگیری ماشین بسیار مهم است. با این حال، بدست آوردن تعداد کافی از داده‌های برچسب‌دار در کاربردهای واقعی اغلب گران و زمانبر است. بنابراین روش‌هایی که دانش موجود در یک دامنه با برچسب‌گذاری مناسب (دامنه مبدا) را به یک دامنه با برچسب‌های معدود یا بدون برچسب (دامنه هدف) منتقل می‌کنند، موثر هستند. به این روش‌ها انتقال یادگیری، تطبیق دامنه و یا تطبیق توزیع می‌گویند. از آنجا که دامنه‌های مبدا و هدف دارای توزیع‌های مختلف هستند، روش‌های بیشمار برای کاهش واگرایی توزیع‌ها پیشنهاد شده است. در این پروژه به بررسی یک روش پارامتری به نام BDA و یک روش غیر پارامتری EasyTL برای انجام تطبیق دامنه می‌پردازیم.

### ۱ مقدمه

لورم ایپسوم متن ساختگی با تولید سادگی نامفهوم از صنعت چاپ و با استفاده از طراحان گرافیک است. چاپگرها و متون بلکه روزنامه و مجله در ستون و سطرآنچنان که لازم است و برای شرایط فعلی تکنولوژی مورد نیاز و کاربردهای متنوع با هدف بهبود ابزارهای کاربردی می باشد. [۱]

### ۲ ادبیات موضوع

لورم ایپسوم متن ساختگی با تولید سادگی نامفهوم از صنعت چاپ و با استفاده از طراحان گرافیک است. چاپگرها و متون بلکه روزنامه و مجله در ستون و سطرآنچنان که لازم است و برای شرایط فعلی تکنولوژی مورد نیاز و کاربردهای متنوع با هدف بهبود ابزارهای کاربردی می باشد. [۲]

### ۳ شرح روش پیشنهادی مقالات

در این بخش ابتدا مسئله تطبیق دامنه را به صورت ریاضی بیان می‌کنیم. سپس مشکلات و چالش‌هایی که در حل این مسئله وجود دارد را بیان خواهیم کرد. در ادامه نیز توضیح خواهیم داد که هر کدام از مقاله‌ها چه روشی را برای حل این مشکلات و چالش‌ها ارائه داده‌اند.

#### ۱.۳ تعریف ریاضی مسئله تطبیق دامنه

ما یک دامنه‌ی برچسب خورده به نام دامنه مبدا و یک دامنه برچسب نخورده به نام دامنه هدف داریم که به ترتیب به صورت  $\{x_{t_j}\}_{j=1}^m$  و  $\{x_{s_i}, y_{s_i}\}_{i=1}^n$  تعریف می‌شود. همچنین فرضیاتی را در مورد فضای ویژگی‌ها  $X_s = X_t$  و فضای برچسب‌ها

$Y_s = Y_t$  و احتمال حاشیه‌ای  $P_s(x_s) \neq P_t(x_t)$  و احتمال شرطی  $P_s(y_s|x_s) \neq P_t(y_t|x_t)$  در نظر می‌گیریم. بنابراین هدف انتقال یادگیری این است که فضای پرچسب‌های دامنه هدف  $Y_t$  را به کمک دامنه مبدا  $D_s$  یاد بگیرد. تطبیق دامنه تلاش می‌کند که با کاهش واگرایی احتمال‌های حاشیه‌ای و احتمال‌های شرطی بین دامنه‌ی مبدا و هدف، مسئله انتقال یادگیری را حل کند به عبارت دیگر واگرایی بین (۱)  $P_s(x_s)$  و  $P_t(x_t)$  (۲)  $P_s(y_s|x_s)$  و  $P_t(y_t|x_t)$  را به حداقل می‌رساند.

### ۲.۳ تطبیق متوازن دامنه در یادگیری انتقال<sup>۱</sup>

بسیاری از روش‌های تطبیق توزیع موجود، یکی از توزیع‌های حاشیه‌ای یا شرطی و یا هر دو را تطبیق می‌دهند. در مقاله‌های اخیر ثابت شده است که استفاده از هر دو توزیع عملکرد بهتری را نتیجه می‌دهد. اما روش‌های کنونی تأثیر هر دو توزیع را یکسان در نظر می‌گیرند در حالی که وقتی مجموعه داده‌ها بسیار متفاوت باشند، به این معنی است که توزیع حاشیه‌ای اهمیت بیشتری دارد و وقتی مجموعه داده‌ها مشابه هستند، به این معنی است که توزیع شرطی به توجه بیشتری نیاز دارد. از این رو، لازم است از هر دو توزیع با وزنی مناسب با اهمیت آن‌ها برای تطبیق استفاده نمود. علاوه بر این، نامتوازن بودن مجموعه داده بر روی تطبیق دامنه تأثیرگذار است که در روش‌های موجود این موضوع در نظر گرفته نمی‌شود. برای حل این دو مشکل، در [۱] دو روش پیشنهاد شده است. روش اول BDA است که نه تنها می‌تواند توزیع‌های حاشیه‌ای و شرطی بین حوزه‌ها را تطبیق دهد، بلکه اهمیت این دو توزیع را به صورت متوازن تنظیم می‌کند. روش دوم W-BDA است که مشکل نامتوازن بودن مجموعه داده را حل می‌کند. W-BDA می‌تواند هنگام انجام تطبیق توزیع، وزن هر کلاس را به طور انطباقی تغییر دهد.

### ۳.۳ BDA

همانطور که توضیح دادیم در تطبیق دامنه، با کاهش واگرایی یا فاصله‌ی بین احتمال‌های حاشیه‌ای و شرطی می‌توانیم دامنه‌های مبدا و هدف را تطبیق دهیم. این موضوع را می‌توانیم به صورت عبارت زیر بیان کنیم:

$$Dist(D_s, D_t) \approx Dist(P(x_s), P(x_t)) + Dist(P(y_s|x_s), P(y_t|x_t)) \quad (۱)$$

روش BDA به عبارت ۱ یک ضریب توازن به نام  $\mu$  اضافه می‌کند که میزان اهمیت توزیع حاشیه‌ای و شرطی را در مسائل مختلف تنظیم و کنترل می‌کند. پس عبارت ۱ تبدیل می‌شود به:

$$Dist(D_s, D_t) \approx (1 - \mu)Dist(P(x_s), P(x_t)) + \mu Dist(P(y_s|x_s), P(y_t|x_t)) \quad (۲)$$

برای حل عبارت ۲ از روش MMD برای تخمین توزیع‌های حاشیه‌ای و توزیع‌های شرطی استفاده می‌کنیم. بنابراین خواهیم داشت:

$$D(D_s, D_t) \approx (1 - \mu) \left\| \frac{1}{n} \sum_{i=1}^n x_{s_i} - \frac{1}{m} \sum_{j=1}^m x_{t_j} \right\|_H^2 + \mu \sum_{c=1}^C \left\| \frac{1}{n_c} \sum_{x_{s_i} \in D_s^{(c)}} x_{s_i} - \frac{1}{m_c} \sum_{x_{t_j} \in D_t^{(c)}} x_{t_j} \right\|_H^2 \quad (۳)$$

در عبارت ۳ ترم اول فاصله‌ی توزیع‌های حاشیه‌ای بین دامنه‌ها را نشان می‌دهد و ترم دوم هم فاصله‌ی توزیع‌های شرطی بین دامنه‌ها را نمایش می‌دهد. با بهره‌گیری از تکنیک‌های ماتریس و جبر خطی عبارت ۳ را می‌توان به صورت زیر نوشت:


$$\min \quad tr \left( A^T X \left( (1 - \mu) M_0 + \mu \sum_{c=1}^C M_c \right) X^T A \right) + \lambda \|A\|_F^2 \quad (۴)$$

$$s.t. \quad A^T X H X^T A = I, \quad 0 \leq \mu \leq 1$$

در عبارت ۴ دو ترم وجود دارد: (۱) تطبیق توزیع‌های حاشیه‌ای و شرطی به همراه ضریب توازن  $\mu$  (۲) ترم مربوط به رگلاریسیون با ضریب رگلاریسیون  $\lambda$ . در این عبارت ۲ قید هم داریم. قید اول بیان می‌کند که داده‌ی تغییر یافته ویژگی‌های داخلی اصل داده را حفظ می‌کند. قید دوم نیز بازه‌ی ضریب توازن را بیان می‌کند.

برای حل عبارت ۴ از ضرائب لاگرانژ استفاده می‌کنیم. بنابراین اگر ضرائب لاگرانژ باشد، خواهیم داشت:

$$L = tr \left( A^T X \left( (1 - \mu) M_0 + \mu \sum_{c=1}^C M_c \right) X^T A \right) + \lambda \|A\|_F^2 + tr \left( (I - A^T X H X^T A) \phi \right) \quad (۵)$$



شکل ۱: نتایج روش EasyTL بر روی مجموعه داده Amazon Review

۴.۳ انتقال یادگیری آسان با استفاده از ساختارهای درون دامنه<sup>۲</sup>

#### ۴ پیاده‌سازی و نتایج

همان طور که در [۲] بیان شده است در روش EasyTL باید دو قسمت زیر را پیاده‌سازی کنیم:

۱. *Intra-domain programming*

۲. *Intra-domain alignment*

بخش *Intra-domain programming* شامل ۳ مرحله نیز می‌باشد:

۱. محاسبه بردار مراکز کلاس‌های دامنه‌ی مبدا  $h_c$ : این قسمت در تابع  $get\_class\_center(Xs, Ys)$  پیاده‌سازی شده است.

۲. محاسبه ماتریس فاصله  $D$ : این قسمت در تابع  $get\_distance\_matrix(Xt, class\_center)$  پیاده‌سازی شده است.

۳. بدست آوردن ماتریس احتمال  $M$  با استفاده از معادله‌ی فلان و بدست آوردن برجسب دامنه هدف: این قسمت در تابع  $solve\_LP(C, nt, Dcj)$  پیاده‌سازی شده است.

سپس از نتایج این سه تابع استفاده می‌کنیم و آن‌ها را در تابع  $intra\_domain\_programming(Xs, Ys, Xt)$  (با هم ترکیب می‌کنیم) در بخش *Intra-domain alignment* کافی است تنها معادله‌ی فلان را پیاده‌سازی کنیم. بدین منظور از تابع  $intra\_domain\_alignment(Xs, Xt)$  استفاده می‌کنیم.

روش EasyTL را می‌توانیم به دو صورت اجرا کنیم. در یک حالت فضای دامنه‌ها را بایکدیگر تراز نمی‌کنیم و فقط بخش *Intra-domain programming* را اجرا می‌کنیم و در حالت دیگر ابتدا فضای دامنه‌ها را به یکدیگر تراز می‌کنیم و سپس طبقه‌بند موجود در دامنه مبدا را به دامنه هدف منتقل می‌کنیم. این روش را بر روی ۴ مجموعه داده آزمایش می‌کنیم و نتایج را مقایسه می‌کنیم. این ۴ مجموعه داده به شرح زیر هستند:


۱. *Amazon Review* یک مجموعه داده تجزیه و تحلیل احساسات است که شامل بررسی‌های مثبت و منفی چهار نوع محصول است: لوازم آشپزخانه، دی وی دی، الکترونیک و کتاب

۲. *Office-Caltech* شامل ۱۰ کلاس از تصاویر در آمازون، DSLR، وب کم و Caltech است.


۳. *Image-CLEF DA* شامل ۱۲ دسته تصویر متعلق به ۳ حوزه است: Caltech، ImageNet و Pascal.

۴. *Office-Home* شامل ۱۵،۵۰۰ تصویر از ۶۵ دسته از ۴ حوزه، Clipart Art، Product و دنیای واقعی است.

نتایج اجرای روش EasyTL را بر روی ۴ تا مجموعه داده ذکر شده را در شکل‌های ۱، ۲، ۳ و ۴ می‌توانید مشاهده کنید. از مقایسه‌ی شکل‌های قسمت (آ) در تمامی شکل‌های ۱، ۲، ۳ و ۴ با نتایج مقاله به این نتیجه می‌رسیم که دقت‌هایی که بدست آوردیم کاملاً مطابق با دقت‌های مقاله است. از شکل‌های قسمت (ب) و (ج) در تمامی شکل‌های ۱، ۲، ۳ و ۴ می‌توانیم به یک نتیجه‌گیری کلی برسیم و آن این است که دقت در حالتی که روش EasyTL را بدون تراز کردن اجرا می‌کنیم با حالتی که



(ج)




(ب)

Accuracy on Image-CLEF DA dataset


Task	EasyTL	EasyTL without alignment
c - i	91.5 %	85.5 %
c - p	77.7 %	72.0 %
i - c	96.0 %	93.3 %
i - p	78.7 %	78.5 %
p - c	95.0 %	91.0 %
p - i	90.3 %	89.5 %

(ا)

شکل ۲: نتایج روش *EasyTL* بر روی مجموعه داده *Image-CLEF DA*



(ج)



(ب)

Accuracy on Office-Caltech dataset

Task	EasyTL	EasyTL without alignment
caltech10 - amazon	52.6 %	50.1 %
caltech10 - webcam	53.9 %	49.5 %
caltech10 - dsir	51.6 %	48.4 %
amazon - caltech10	42.3 %	43.0 %
amazon - webcam	43.1 %	40.7 %
amazon - dsir	48.4 %	38.9 %
webcam - caltech10	35.4 %	29.7 %
webcam - amazon	38.2 %	35.2 %
webcam - dsir	79.6 %	77.1 %
dsir - caltech10	36.1 %	31.2 %
dsir - amazon	38.3 %	31.9 %
dsir - webcam	86.1 %	69.5 %


(ا)

شکل ۳: نتایج روش *EasyTL* بر روی مجموعه داده *Office-Caltech*


تراز کردن را در نظر نمی‌گیریم تفاوت چندانی ندارد اما از لحاظ زمان و سرعت روش *EasyTL* بدون تراز کردن بسیار سریعتر است و نیاز به زمان کمتری دارد. بنابراین در کاربردهایی که دقت برای ما از اهمیت بالایی برخوردار است می‌توانیم از روش *EasyTL* با تراز کردن استفاده کنیم و در کاربردهایی که سرعت برای ما مهم است روش *EasyTL* را بدون تراز کردن استفاده کنیم. به عبارت دیگر در اینجا با یک مصالحه‌ای رو به رو هستیم که با توجه به کاربرد باید تصمیم بگیریم که از کدام روش استفاده کنیم.

## مراجع

- [1] J. Wang, Y. Chen, S. Hao, W. Feng, and Z. Shen. Balanced distribution adaptation for transfer learning. In *2017 IEEE International Conference on Data Mining (ICDM)*, pages 1129–1134. IEEE, 2017.
- [2] J. Wang, Y. Chen, H. Yu, M. Huang, and Q. Yang. Easy transfer learning by exploiting intra-domain structures. In *2019 IEEE International Conference on Multimedia and Expo (ICME)*, pages 1210–1215. IEEE, 2019.



(ج)



(ب)

Accuracy on Office-Home DA dataset

Task	EasyTL	EasyTL without alignment
Art - Clipart	52.8 %	51.5 %
Art - Product	72.1 %	68.1 %
Art - RealWorld	75.9 %	74.2 %
Clipart - Art	55.0 %	53.1 %
Clipart - Product	65.9 %	62.9 %
Clipart - RealWorld	67.6 %	65.3 %
Product - Art	54.4 %	52.8 %
Product - Clipart	46.9 %	45.8 %
Product - RealWorld	74.7 %	73.5 %
RealWorld - Art	63.8 %	62.2 %
RealWorld - Clipart	52.3 %	50.1 %
RealWorld - Product	77.9 %	76.0 %

(ا)

شکل ۴: نتایج روش *EasyTL* بر روی مجموعه داده *Office-Home*